

Breast Cancer Wisconsin (Diagnostic)

Luís Gustavo
Aramys Almeida Matos

Inteligência Computacional

4 de dezembro de 2016

- Exames para câncer de mama.
- Características do núcleo de células computadas a partir de imagens digitalizadas
- 30 variáveis de entrada
- 1 variável de saída
- Raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria, dimensão fractal




- Problema de classificação
- Identificar se o câncer é benigno ou maligno.
- Aplicar e avaliar os modelos de classificação:
 - Classificador Bayesiano Simples
 - Classificador Bayesiano Quadrático
 - Regressão Logística
 - Perceptron
 - Perceptron Múltiplas Camadas

Matriz de Correlação

Distância Euclidiana




Histogramas

Smoothness



Histogramas

Texture



Python

- SciPy
 - *NumPy*
 - *matplotlib*
 - *pandas*: Python Data Analysis Library
- *scikit-learn*: Machine Learning in Python

Matlab

- Statistics and Machine Learning Toolbox

Para cada método de classificação foi feito:

- Validação cruzada de 10 ciclos
- Matriz de confusão (média de cada ciclo)
- Métricas de acurácia, precisão, recuperação.

Classificador Bayesiano Simples (Naive Bayes)

- Aplicação do teorema de Bayes
- Supoe que cada par de variáveis é independente

Theorem (Teorema de Bayes)

$$P(y|x_1 \dots x_n) = \frac{P(y)P(x_1, \dots, x_n|y)}{P(x_1, \dots, x_n)}$$

Onde:

y é a variável de saída que identifica a classe

$x = [x_1, \dots, x_n]$ é o vetor de entrada

Classificador Bayesiano (Naive Bayes) - Resultados

Avaliação dos resultados

• $ACC = 0.94$

	\hat{C}_1 (Predita)	\hat{C}_2 (Predita)
C_1	18.80	2.40
C_2	1.20	34.50

Tabela: Matriz de confusão




Figura: Precisão e Recall

Classificador Bayesiano Quadrático

- Um classificador com uma fronteira de decisão quadrática, gerado pela densidades condicionais dos dados e utilizando a regra de Bayes.
- A decisão é calculada pela função discriminante:

Theorem (Função Discriminante)

$$g_i(x(t)) = \ln P(C_i | x(t)) = \ln p(x(t) | C_i) + \ln P(C_i)$$

Classificador Bayesiano Quadrático - Resultados

Avaliação dos resultados

- $ACC = 0.96$

	\hat{C}_1 (Predita)	\hat{C}_2 (Predita)
C_1	20.00	1.20
C_2	1.20	34.50

Tabela: Matriz de confusão




Figura: Precisão e Recall

- Na regressão logística, a saída do modelo é uma aproximação da probabilidade a posteriori.
- A função discriminante é calculada pela função sigmoide, ou função logística ou logit

Theorem (Função Logística)

$$g_i(x(t)|\theta_i) = \frac{1}{1 + \exp(\hat{x}(t)\theta_i)}$$

Onde:

$$\hat{x}(t) = [1, x(t)]e\theta_i = [\theta_{i0}, \theta_{i1}]^T$$

Avaliação dos resultados

- $ACC = 0.96$

	\hat{C}_1 (Predita)	\hat{C}_2 (Predita)
C_1	20.00	1.20
C_2	1.10	34.60

Tabela: Matriz de confusão




Figura: Precisão e Recall

O Perceptron utiliza o modelo McCulloch-Pitts para o neurônio artificial. O processamento de cada unidade é dado por:

McCulloch-Pitts

$$u(t) = h(z(t)) = h\left(\theta_0 + \sum_{i=1}^n x_i(t)\theta_i\right)$$

Onde:

$u(t)$: valor de ativação

$z(t)$: potencial de ativações

h : função de ativação

$x_i(t)$: entradas do neurônio

Scikit Learn

```
class sklearn.linear_model.Perceptron(penalty=None,  
    alpha=0.0001, fit_intercept=True, n_iter=5,  
    shuffle=True, verbose=0, eta0=1.0, n_jobs=1,  
    random_state=0, class_weight=None, warm_start=False)
```

É uma especialização do `sklearn.linear_model.SGDClassifier`.

Avaliação dos resultados

- $ACC = 0.96$

	\hat{C}_1 (Predita)	\hat{C}_2 (Predita)
C_1	20.40	0.80
C_2	1.40	34.30

Tabela: Matriz de confusão




Figura: Precisão e Recall

Perceptron de Múltiplas Camadas

- asdx

Scikit Learn

```
class sklearn.neural_network.MLPClassifier
(hidden_layer_sizes=(100, ), activation='relu',
 solver='adam', alpha=0.0001, batch_size='auto',
 learning_rate='constant', learning_rate_init=0.001,
 power_t=0.5, max_iter=200, shuffle=True,
 random_state=None, tol=0.0001, verbose=False,
 warm_start=False, momentum=0.9, nesterovs_momentum=True,
 early_stopping=False, validation_fraction=0.1,
 beta_1=0.9, beta_2=0.999, epsilon=1e-08)
```

Perceptron de Múltiplas Camadas - Resultados

Avaliação dos resultados

- $ACC = 0.97$

	\hat{C}_1 (Predita)	\hat{C}_2 (Predita)
C_1	20.20	1.00
C_2	0.40	35.30

Tabela: Matriz de confusão




Figura: Precisão e Recall