Universidade Federal do Rio de Janeiro

Inteligência Computacional

Breast Cancer Wisconsin

Nomes:
Aramys Almeida Matos
Luís Gustavo Oliveira Silva

Professor:
Alexandre Evsukoff

1 Introdução

Este trabalho será desenvolvido sobre o *dataset Breast Cancer Wisconsin (Diagnostic)*. Este *dataset* possui como variáveis características computadas a partir de imagens digitalizadas de exames de mama por punção aspirativa por agulha fina. Os dados descrevem características do núcleo das células presentes na imagem.

2 Caracterização

2.1 Dados

Inicialmente é importante ressaltar que o conjunto de dados gerado pelos exames é tridimensional. Para cada registro (paciente) existe um conjunto de células, cada uma com os seguintes atributos.

1. Raio (média das distâncias do centro para pontos no perímetro)
2. Textura
3. Perímetro
4. Área
5. Suavidade
6. Compacidade
7. Concavidade
8. Pontos côncavos
9. Simetria
10. Dimensão Fractal

De forma a eliminar a terceira dimensão (do conjunto de células), para cada conjunto de células o *UCI Machine Learning* forneceu o dataset com valores de média, desvio(erro) padrão e o pior valor dos atributos no universo das células, resultando em 30 variáveis de entrada. O dataset conforme obtido possui as variáveis como segue:

1. radius_mean
2. texture_mean
3. perimeter_mean
4. area_mean
5. smoothness_mean
6. compactness_mean
7. concavity_mean
8. concave points_mean
9. symmetry_mean
10. fractal_dimension_mean
11. radius_se
12. texture_se
13. perimeter_se
14. area_se
15. smoothness_se
16. compactness_se
17. concavity_se
18. concave points_se
19. symmetry_se
20. fractal_dimension_se
21. radius_worst

22. texture_worst
23. perimeter_worst
24. area_worst
25. smoothness_worst
26. compactness_worst
27. concavity_worst
28. concave points_worst
29. symmetry_worst
30. fractal_dimension_worst

A variável de saída é o diagnóstico (maligno ou benigno codificados como -1 e 1 respectivamente). Existe uma coluna com o ID do paciente que será eliminada ser irrelevante. O dataset apresenta 357 amostras benignas e 212 amostras malignas.

2.2 Estatísticas Básicas e Histogramas

- Radius

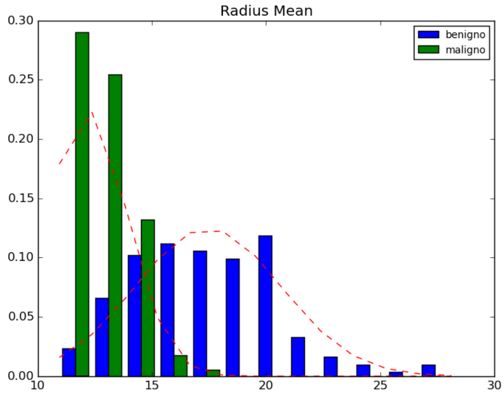

Figura 1: Mean

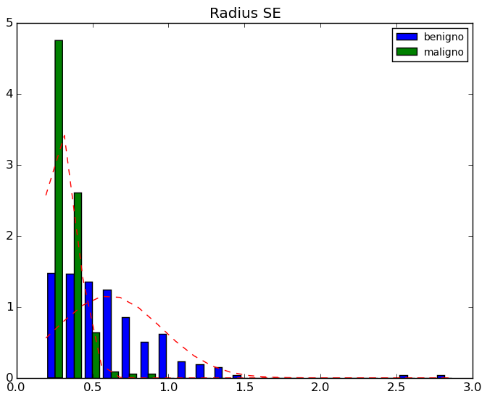

Figura 2: Standard Error

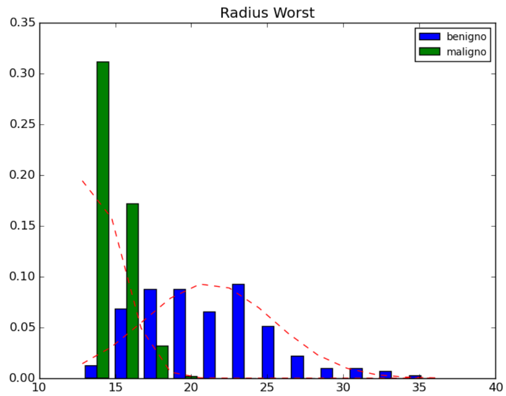

Figura 3: Worst

Tabela 1: Radius

	radius_mean	radius_se	radius_worst
Máximo	28.11	2.873	36.04
Mínimo	6.981	0.1115	7.93
Média	14.12729	0.405172	16.26919
Desvio padrão	3.524049	0.277313	4.833242
Percentil 25	11.7	0.2324	13.01
Percentil 50	13.37	0.3242	14.97
Percentil 75	15.78	0.4789	18.79

Análise: Para a variável Radius mean, vemos que a maioria de seus valores se concentram mais proximos da média que é 14,13. Para Radius Standard Error, também têm um coportamento semelhante a uma função de cauda longa, porém não temos a presença de valores no intervalo entre 1,6 e 2,4. Já para a variável Radius Worst, tem um comportamento semelhante à variável Radius mean.

- Texture

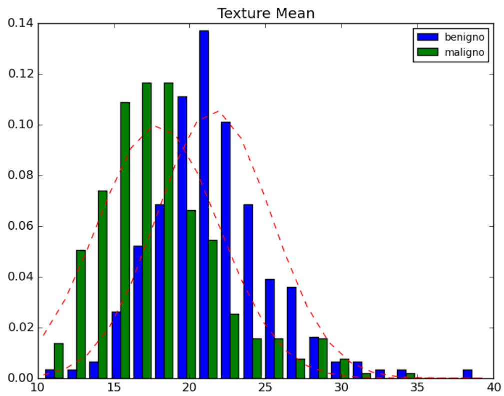

Figura 4: Mean

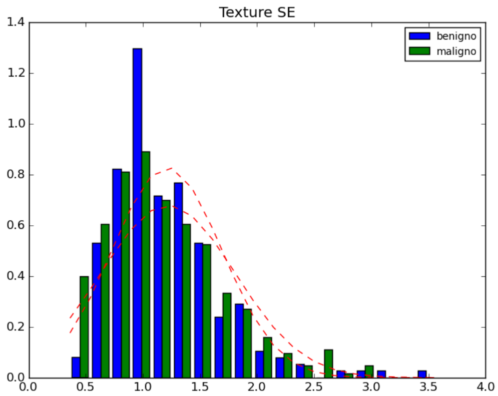

Figura 5: Standard Error

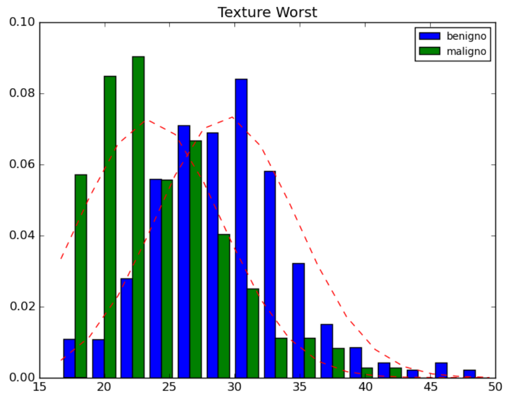

Figura 6: Worst

Tabela 2: Texture

	texture_mean	texture_se	texture_worst
Máximo	39.28	4.885	49.54
Mínimo	9.71	0.3602	12.02
Média	19.28964851	1.216853427	25.67722
Desvio padrão	4.301035768	0.551648393	6.146258
Percentil 25	16.17	0.8339	21.08
Percentil 50	18.84	1.108	25.41
Percentil 75	21.8	1.474	29.72

Análise: Podemos perceber que a variável Texture Mean, tem um comportamento que lembra a uma função Gaussiana, que de certa forma é espelhada em realação a média, com a exceção dos outliers. Em Texture Standart Error, a média é 1,22 e seus valores estão localizados proóximos á média, porém temos uma certa quantidade de valores distantes, mesmo considerando o desvio parão, e um valor máximo muito alto. Em Texture Worst, vemos que seu comportamento se assemelha a Texture Mean.

- Perimeter

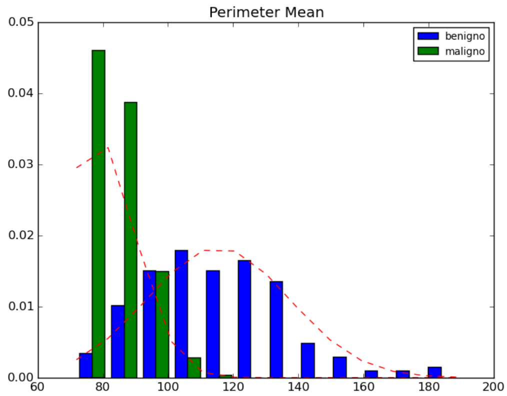

Figura 7: Mean

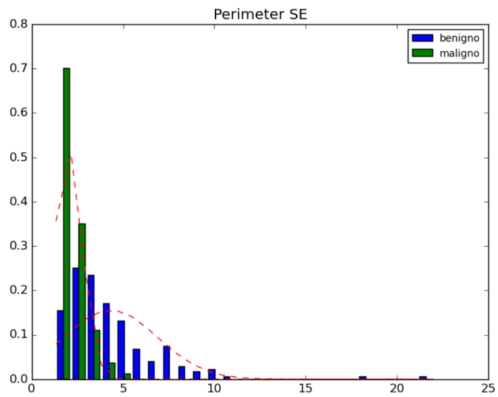

Figura 8: Standard Error

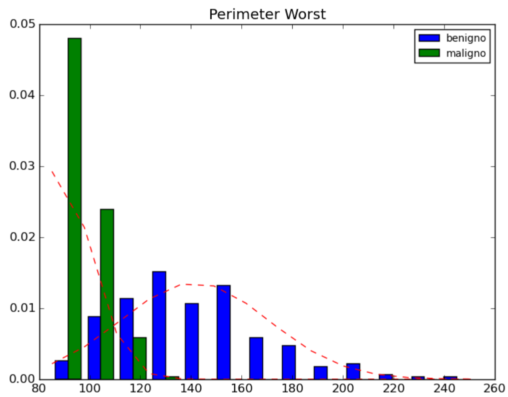

Figura 9: Worst

Tabela 3: Perimeter

	perimeter_mean	perimeter_se	perimeter_worst
Máximo	188.5	21.98	251.2
Mínimo	43.79	0.757	50.41
Média	91.96903339	2.866059227	107.2612
Desvio padrão	24.29898104	2.021854554	33.60254
Percentil 25	75.17	1.606	84.11
Percentil 50	86.24	2.287	97.66
Percentil 75	104.1	3.357	125.4

Análise: Em Perimeter Standard Error, vemos a presença de outliers, como por exemplo o valor máximo que é 21,98, enquanto sua média é 2.87. E em Perimeter Worst, vemos que possui um desvio padrão alto e seus valores estão distribuídos de forma distante da média.

- Area

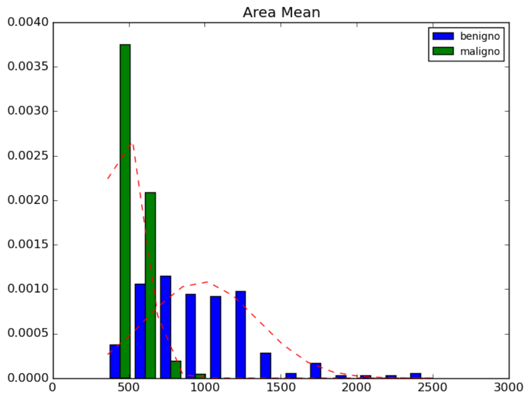

Figura 10: Mean

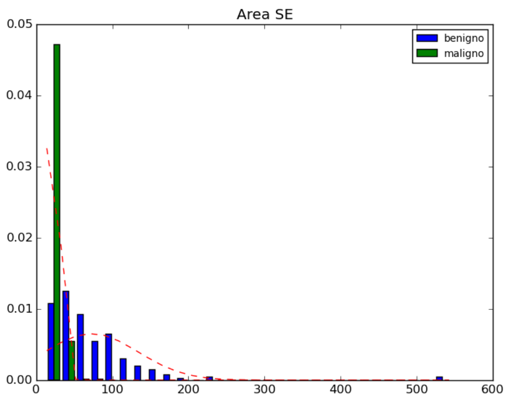

Figura 11: Standard Error

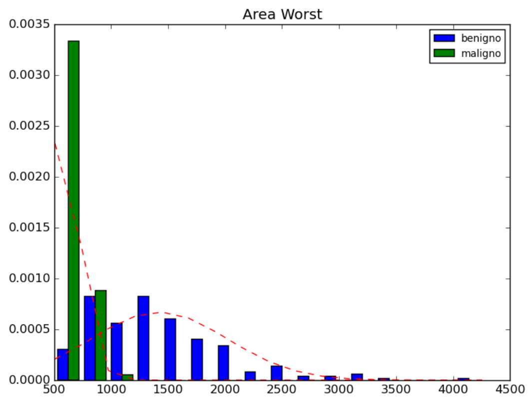

Figura 12: Worst

Tabela 4: Area

	area_mean	area_se	area_worst
Máximo	2501	542.2	4254
Mínimo	143.5	6.802	185.2
Média	654.8891037	40.33707909	880.5831283
Desvio padrão	351.9141292	45.49100552	569.3569927
Percentil 25	420.3	17.85	515.3
Percentil 50	551.1	24.53	686.5
Percentil 75	782.7	45.19	1084

Análise: Na variável Area Mean, vemos que ela possui um desvio padrão grande, sendo maior que a metade da média, assim como em Area Worst. Em Area Standard Error, vemos que a variável tem um compartamento semelhante a uma função de cauda longa e temos uma valor bem distante que é o valor máximo (2501,00).

- Smoothness

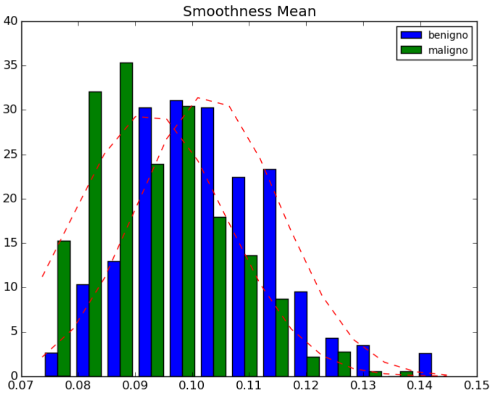

Figura 13: Mean

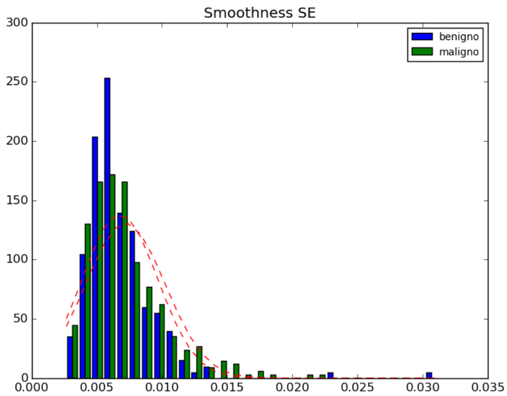

Figura 14: Standard Error

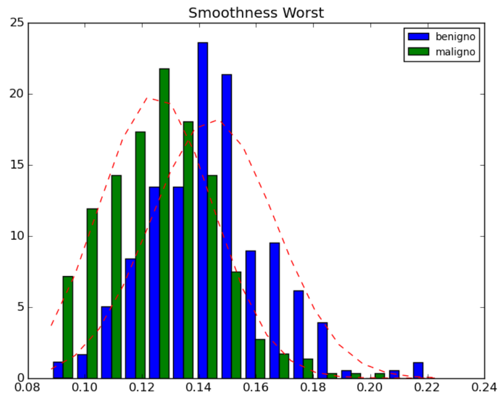

Figura 15: Worst

Tabela 5: Smoothness

	smoothness_mean	smoothness_se	smoothness_worst
Máximo	0.1634	0.03113	0.2226
Mínimo	0.05263	0.001713	0.07117
Média	0.096360281	0.007040979	0.132368594
Desvio padrão	0.014064128	0.003002518	0.022832429
Percentil 25	0.08637	0.005169	0.1166
Percentil 50	0.09587	0.00638	0.1313
Percentil 75	0.1053	0.008146	0.146

Análise: Podemos ver que tanto Smoothness Mean quanto em Worst, elas tem uma aparência semelhante a uma função Gaussiana e possuem um desvio padrão pequeno, já em Smoothness Standard Error, vemos que ela possui um desvio padrão alto e existe a presença de outliers como o seu valor máximo (0,16340).

- Compactness

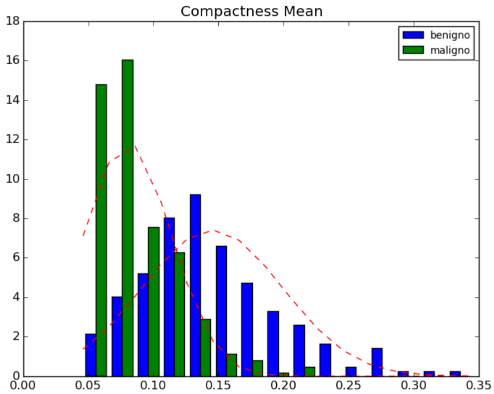

Figura 16: Mean

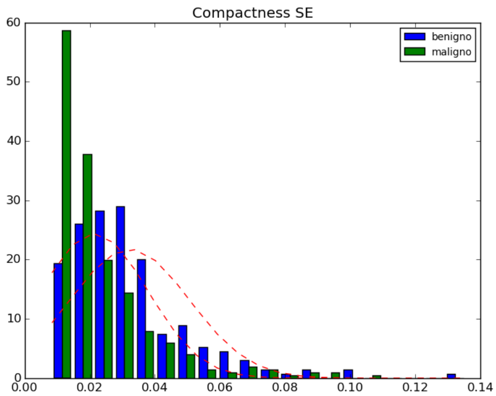

Figura 17: Standard Error

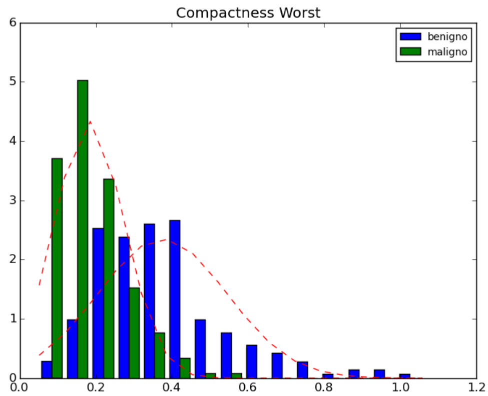

Figura 18: Worst

Tabela 6: Compactness

	compactness_mean	compactness_se	compactness_worst
Máximo	0.3454	0.1354	1.058
Mínimo	0.01938	0.002252	0.02729
Média	0.104340984	0.025478139	0.254265
Desvio padrão	0.052812758	0.017908179	0.157336
Percentil 25	0.06492	0.01308	0.1472
Percentil 50	0.09263	0.02045	0.2119
Percentil 75	0.1304	0.03245	0.3391

Análise: Aqui percebemos que as 3 variáveis possuem um desvio padrão alto e seus valores máximos se destoam bantante.

- Concavity

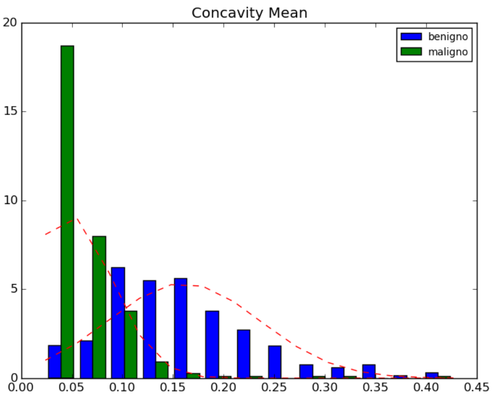

Figura 19: Mean

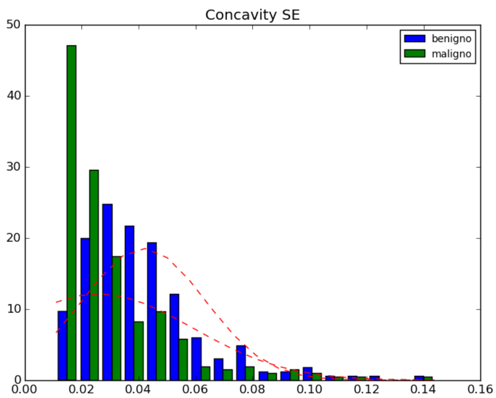

Figura 20: Standard Error

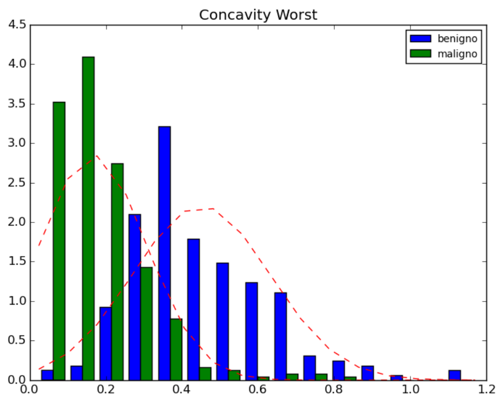

Figura 21: Worst

Tabela 7: Concavity

	concavity_mean	concavity_se	concavity_worst
Máximo	0.4268	0.396	1.252
Mínimo	0	0	0
Média	0.088799316	0.031893716	0.272188483
Desvio padrão	0.079719809	0.03018606	0.208624281
Percentil 25	0.02956	0.01509	0.1145
Percentil 50	0.06154	0.02589	0.2267
Percentil 75	0.1307	0.04205	0.3829

Análise: Nas 3 variáveis percebemos que o seus valores se concentram mais proximos de 0 e a ocorrência desses valores vão decaindo conforme se afastam de 0.

- Concave points

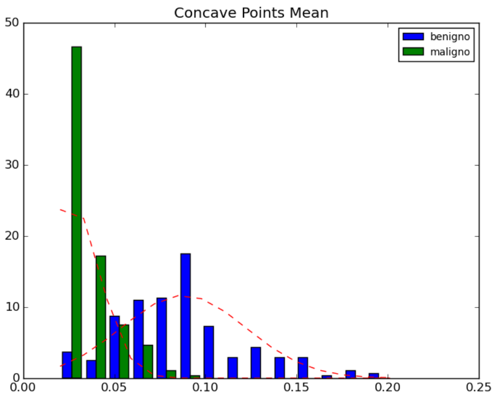

Figura 22: Mean

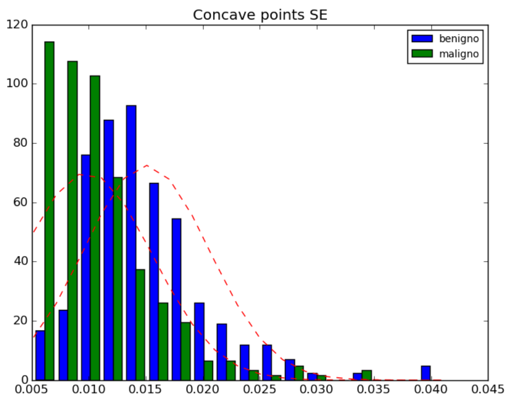

Figura 23: Standard Error

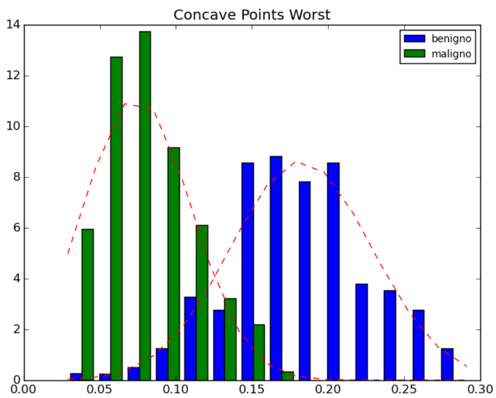

Figura 24: Worst

Tabela 8: Concave points

	concave points_mean	concave points_se	concave points_worst
Máximo	0.2012	0.05279	0.291
Mínimo	0	0	0
Média	0.048919146	0.011796	0.114606
Desvio padrão	0.038802845	0.00617	0.065732
Percentil 25	0.02031	0.007638	0.06493
Percentil 50	0.0335	0.01093	0.09993
Percentil 75	0.074	0.01471	0.1614

Análise: Aqui vemos que a variável Cancave points mean, tem um comportamento semelhante à uma função de cauda longa e que a variável Cancave Points Standard Error possui alguns outliers, como o valor máximo por exemplo.

- Symmetry

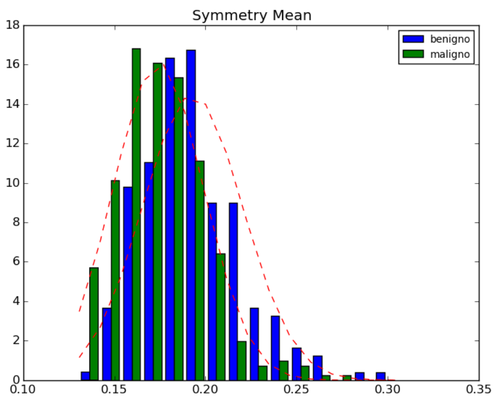

Figura 25: Mean

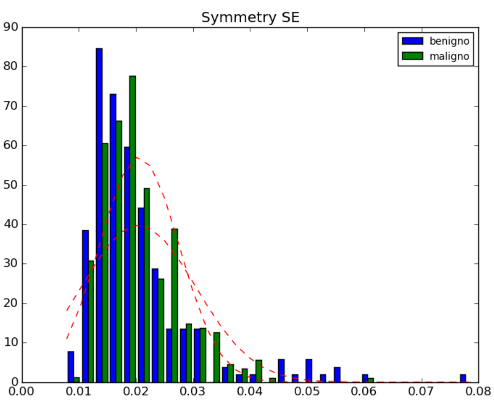

Figura 26: Standard Error

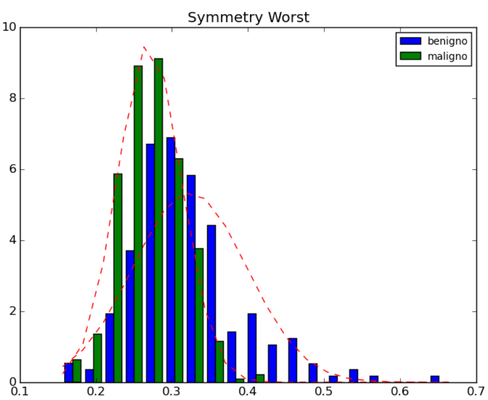

Figura 27: Worst

Tabela 9: Symmetry

	symmetry_mean	symmetry_se	symmetry_worst
Máximo	0.304	0.07895	0.6638
Mínimo	0.106	0.007882	0.1565
Média	0.181162	0.020542	0.290076
Desvio padrão	0.027414	0.008266	0.061867
Percentil 25	0.1619	0.01516	0.2504
Percentil 50	0.1792	0.01873	0.2822
Percentil 75	0.1957	0.02348	0.3179

Análise - A variável Symmetry mean possui um comportamento semelhante a uma função Gaussiana e tanto Symmetry Standard Error, quanto Wosrt possuem valores máximos distantes da média.

- Fractal Dimension

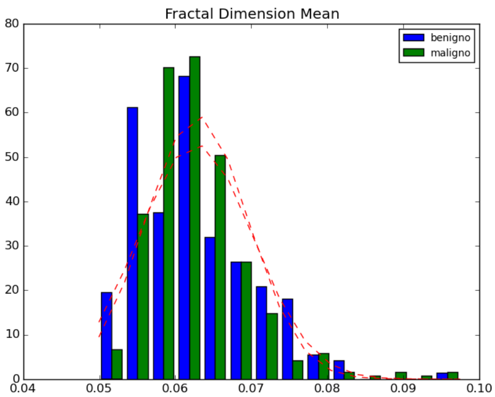

Figura 28: Mean

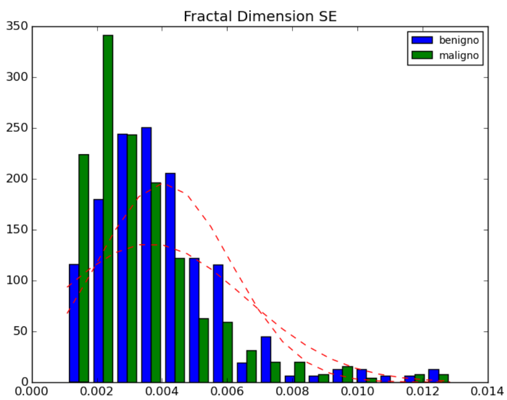

Figura 29: Standard Error

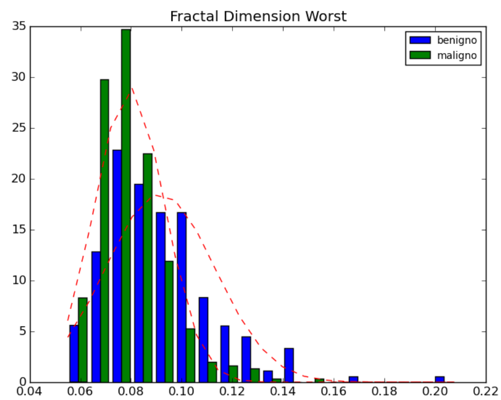

Figura 30: Worst

Tabela 10: Fractal dimension

	fractal_dimension_mean	fractal_dimension_se	fractal_dimension_worst
Máximo	0.09744	0.02984	0.2075
Mínimo	0.04996	0.000895	0.05504
Média	0.06279761	0.003795	0.083945817
Desvio padrão	0.007060363	0.002646	0.018061267
Percentil 25	0.0577	0.002248	0.07146
Percentil 50	0.06154	0.003187	0.08004
Percentil 75	0.06612	0.004558	0.09208

Análise: Podemos ver que apartir da média, a ocorrência dos valores das váreiaveis vão diminuindo conforme se distanciam da média.

A partir dos histogramas podemos avaliar que em geral não revelou características indesejáveis como distribuições multimodais. Conforme comentado algumas apresentaram assimetria.

2.3 Matriz de Correlação

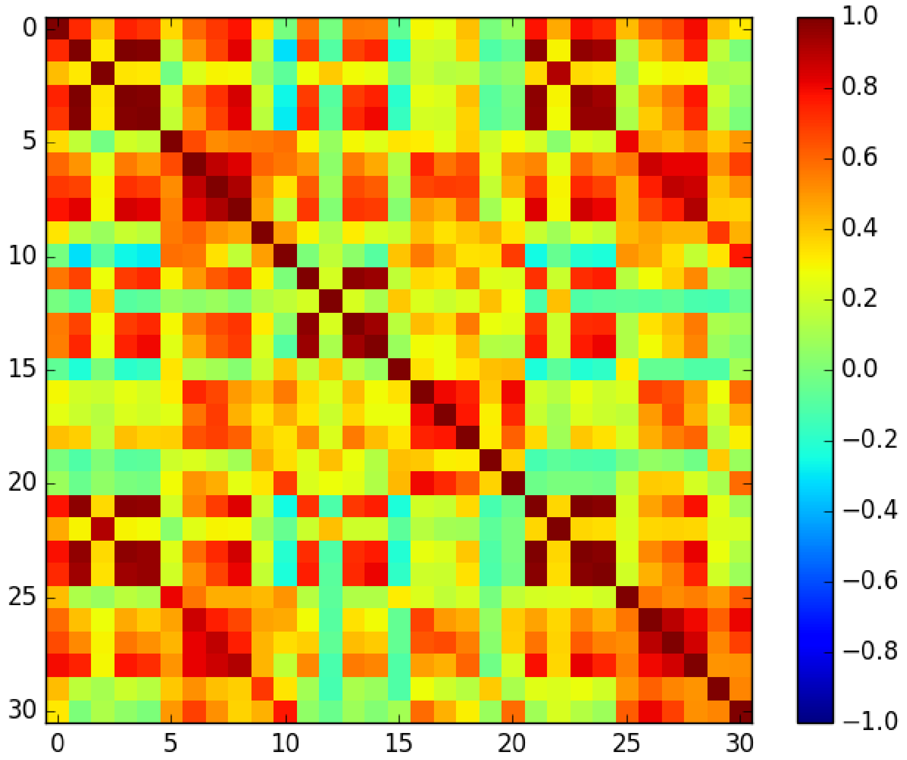

Figura 31: Matriz de Correlação

A partir da matriz podemos concluir que as seguintes variáveis estão fortemente correlacionadas (apresentam coeficiente de correlação acima de 0.9):

- Radius Mean, Perimeter Mean
- Radius Mean, Area Mean
- Radius Mean, Radius Worst
- Radius Mean, Perimeter Worst
- Radius Mean, Area Worst
- Texture Mean, Texture Worst
- Perimeter Mean, Area Mean
- Perimeter Mean, Radius Worst
- Perimeter Mean, Perimeter Worst
- Perimeter Mean, Area Worst
- Area Mean, Radius Worst
- Area Mean, Perimeter Worst
- Area Mean, Area Worst
- Concavity Mean, Concave Points Mean
- Concave Points Mean, Concave Points Worst
- Radius SE, Perimeter SE
- Radius SE, Area SE
- Perimeter SE, Area SE
- Radius Worst, Perimeter Worst
- Radius Worst, Area Worst
- Perimeter Worst, Area Worst

As seguintes variáveis apresentaram correlação negativa:

- Radius Mean, Fractal Dimension Mean
- Radius Mean, Texture SE
- Radius Mean, Smoothness SE
- Radius Mean, Symmetry SE
- Radius Mean, Fractal Dimension SE
- Texture Mean, Smoothness Mean
- Texture Mean, Fractal Dimension Mean
- Perimeter Mean, Fractal Dimension Mean
- Perimeter Mean, Texture SE
- Perimeter Mean, Smoothness SE
- Perimeter Mean, Symmetry SE
- Perimeter Mean, Fractal Dimension SE
- Area Mean, Fractal Dimension Mean
- Area Mean, Texture SE
- Area Mean, Smoothness SE
- Area Mean, Symmetry SE
- Area Mean, Fractal Dimension SE
- Fractal Dimension Mean, Area SE
- Fractal Dimension Mean, Radius Worst
- Fractal Dimension Mean, Texture Worst
- Fractal Dimension Mean, Perimeter Worst
- Fractal Dimension Mean, Area Worst
- Texture SE, Radius Worst
- Texture SE, Perimeter Worst
- Texture SE, Area Worst
- Texture SE, Smoothness Worst
- Texture SE, Compactness Worst
- Texture SE, Concavity Worst

- Texture SE, Concave Points Worst
- Texture SE, Symmetry Worst
- Texture SE, Fractal Dimension Worst
- Smoothness SE, Radius Worst
- Smoothness SE, Texture Worst
- Smoothness SE, Perimeter Worst
- Smoothness SE, Area Worst
- Smoothness SE, Compactness Worst
- Smoothness SE, Concavity Worst
- Smoothness SE, Concave Points Worst
- Smoothness SE, Symmetry Worst
- Symmetry SE, Radius Worst
- Symmetry SE, Texture Worst
- Symmetry SE, Perimeter Worst
- Symmetry SE, Area Worst
- Symmetry SE, Smoothness Worst
- Symmetry SE, Concave Points Worst
- Fractal Dimension SE, Radius Worst
- Fractal Dimension SE, Texture Worst
- Fractal Dimension SE, Perimeter Worst
- Fractal Dimension SE, Area Worst

2.4 Matriz de Distâncias

As figuras 32 e 33 mostram a matriz de distâncias, utilizando a Distância Euclidiana:

$$dist_E(\nu, \upsilon) = ||\nu - \upsilon||$$

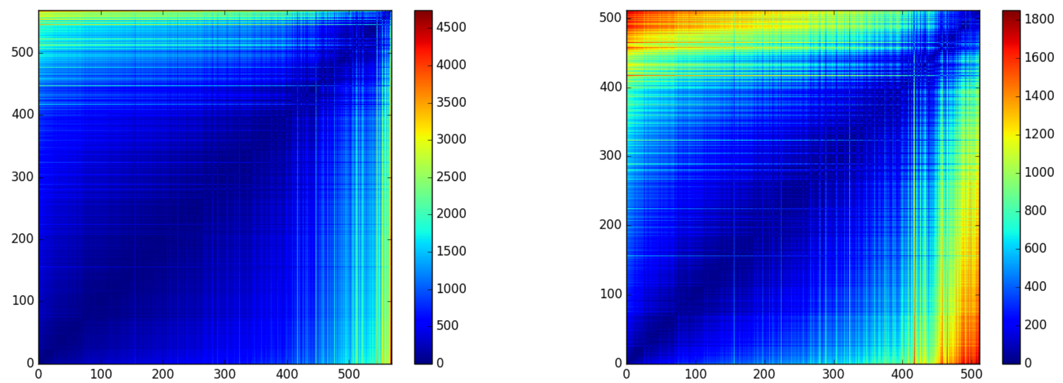

(a) Antes da retirada de outliers (b) Após da retirada de outliers

Figura 32: Matriz de distâncias

A matriz de distâncias para o conjunto de registros original pode ser observada na figura 32a. Foi realizado o processo de retirada de outliers baseado na distância média $m_i = \frac{1}{N}\Sigma_{j=1}^{N} d_{ij}$. Foram removidos os $P_{out} = 10\%$ registros correspondentes aos maiores valores. A matriz de distâncias do conjunto de dados resultante pode ser vista na figura 32b.

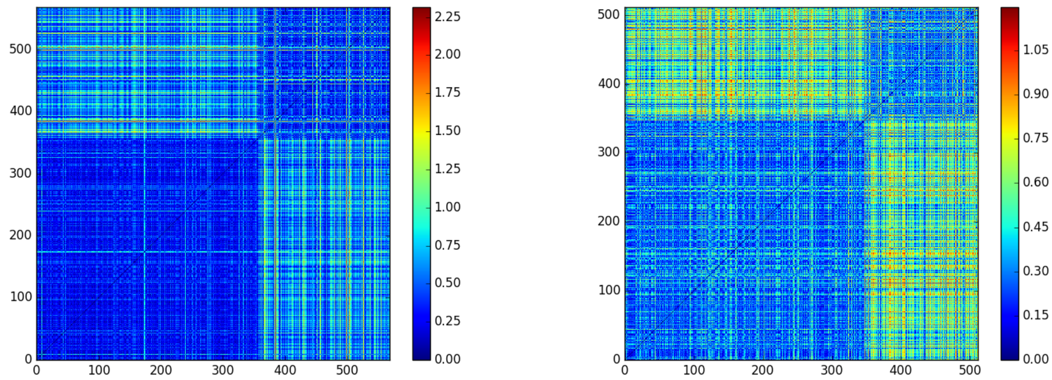

(a) Antes da retirada de outliers (b) Após da retirada de outliers

Figura 33: Matriz de distâncias com z-score

Como o conjunto de dados contém variáveis em unidades e escalas diferentes, o que dificulta a avaliação da matriz de distâncias pois os outliers de algumas variáveis acabam dominando. Assim, foi feita uma padronização das variáveis por meio da estimativa z-score e a matriz de distâncias resultante pode ser vista na figura 33.

3 Formulação do Problema

Consiste em um problema de classificação. Deseja-se desenvolver um classificador capaz de predizer a classe do registro (maligno ou benigno).

Para solução deste problema serão aplicados os modelos de classificação a seguir e avaliados os resultados.

- Classificador Bayesiano Simples
- Classificador Bayesiano Quadrático
- Regressão Logística
- Perceptron
- Perceptron Múltiplas Camadas
- SVM

Para os testes será utilizada a metodologia de validação cruzada de 10 ciclos. A cada iteração o dataset é dividido em subconjuntos complementares. O modelo é ajustado com o conjunto de treinamento e aplicado para predizer a saída do conjunto de teste. O resultado final é obtido como a média de cada iteração.

Para avaliar o desempenho do classificador, os resultados preditos pelo teste são comparado com os resultados reais e contabilizada a matriz de confusão. A partir dela são calculados as seguintes métricas:

- Acurácia

- Erro global
- Precisão
- Recuperação

4 Apresentação da Tecnologia

Para a implementação e execução dos algoritmos serão usadas as seguintes ferramentas:
A linguagem Python apresenta diversas bibliotecas úteis como:

- *SciPy*: Ecossistema de softwares para matemática, ciência e engenharia. Contém os pacotes:
  - *NumPy*
  - *matplotlib*
  - *pandas*: Python Data Analysis Library
- *scikit-learn*: Machine Learning in Python

5 Classificador Bayesiano Simples

5.1 Formulação matemática

O Classificador Bayesiano baseia-se na aplicação do Teorema de Bayes com a suposição de independência entre cada par de variáveis.

$$P(y|x_1 \dots x_n) = \frac{P(y)P(x_1, \dots, x_n|y)}{P(x_1, \dots, x_n)}$$

Onde:
y é a variável de saída que identifica a classe
$x = [x_1, \dots, x_n]$ é o vetor de entrada

5.2 Resultados

O dataset não é linearmente separável portanto os resultados não foram tão satisfatórios.

Tabela 11: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	18.80	2.40
C_2	1.20	34.50

- $ACC = 93.67\%$
- $ERR =$
- $AUC = 0.9266$
- $PRE(C1) = 0.94$
- $REC(C1) = 0.8868$
- $PRE(C2) = 0.9350$
- $REC(C2) = 0.9664$

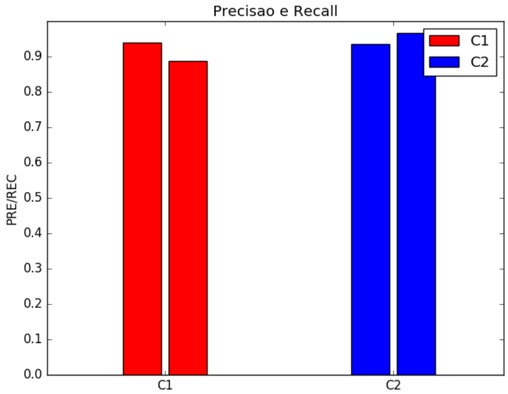

Figura 34: Precisão e Recall

6 Classificador Bayesiano Quadrático

6.1 Formulação Matemática

É um classificador com uma fronteira de decisão quadrática, gerado pela densidades condicionais dos dados e utilizando a regra de Bayes.

A decisão é calculada pela função discriminante:

$$g_i(x(t)) = lnP(C_i|x(t)) = lnP(x(t)|C_i) + lnP(C_i)$$

6.2 Resultados

Tabela 12: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.00	1.20
C_2	1.20	34.50

- $ACC = 95.78\%$
- $AUC = 0.9549$
- $ERR =$
- $PRE(C1) = 0.9434$
- $REC(C1) = 0.9434$
- $PRE(C2) = 0.9664$
- $REC(C2) = 0.9664$

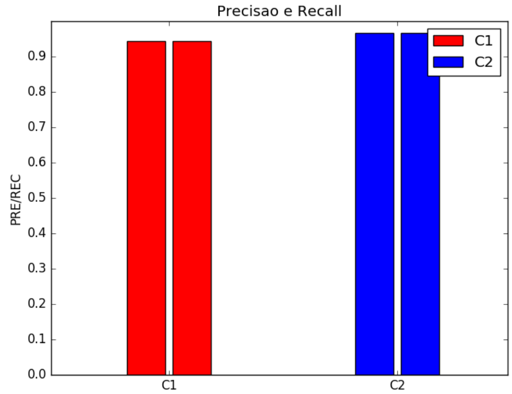

Figura 35: Precisão e Recall

7 Regressão Logística

7.1 Formulação Matemática

Na regressão logística, a saída do modelo é uma aproximação da probabilidade a posteriori.

A função discriminante é calculada pela função sigmoide, ou função logística ou logit:

$$g_i(x(t)|\theta_i)) = \frac{1}{1 + exp(\hat{x}(t)\theta_i)}$$

Onde:

$$\hat{x}(t) = [1, x(t)] \quad e \quad \theta_i = [\theta_{\text{i}0}, \theta_{\text{i}1}]^T$$

7.2 Resultados

Tabela 13: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.00	1.20
C_2	1.10	34.60

- $ACC = 95.96\%$
- $ERR =$
- $AUC = 0.9563$
- $PRE(C1) = 0.9479$
- $REC(C1) = 0.9434$
- $PRE(C2) = 0.9665$
- $REC(C2) = 0.9692$

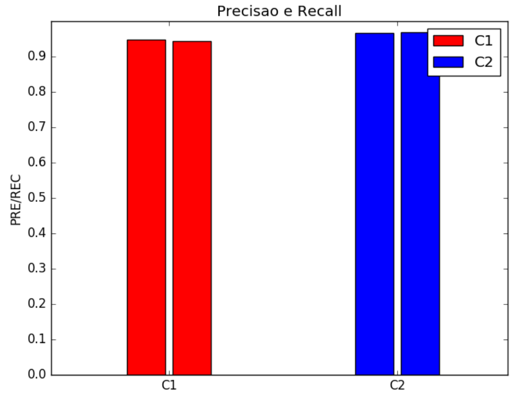

Figura 36: Precisão e Recall

8 Perceptron

8.1 Formulação Matemática

O Perceptron utiliza o modelo McCulloch-Pitts para o neurônio artificial. O processamento de cada unidade é dado por:

$$u(t) = h(z(t)) = h\left(\theta_0 + \sum_{i=1}^{n} x_i(t)\theta_i\right)$$

onde:
$u(t)$: valor de ativação
$z(t)$: potencial de ativaçãos
h: função de ativação
$x_i(t)$: entradas do neurônio

8.2 Resultados

Tabela 14: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.40	0.80
C_2	1.40	34.30

- $ACC = 96.13\%$
- $ERR =$
- $AUC = 0.9615$
- $PRE(C1) = 0.9358$
- $REC(C1) = 0.9623$
- $PRE(C2) = 0.9772$
- $REC(C2) = 0.9608$

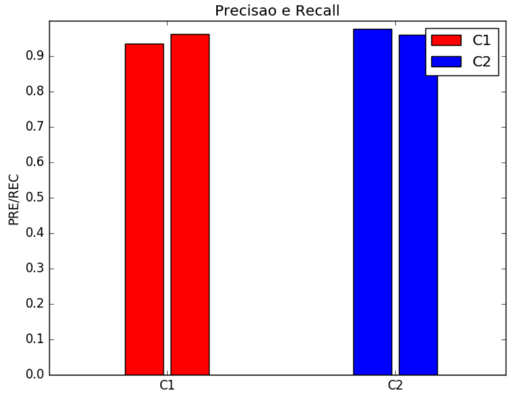

Figura 37: Precisão e Recall

9 Perceptron de Múltiplas Camadas (MLP)

9.1 Formulação Matemática

Uma rede-neural MLP apresenta uma camada de entrada que não realiza processamento com a dimensão do vetor de entrada, uma ou mais camadas intermediárias que realizam processamento e uma camada de saída que, num problema de classificação é o vetor com as estimativas das variáveis indicadoras. O modelo McCulloch-Pitts é utilizado nas unidades das camadas intermediárias e de saída.

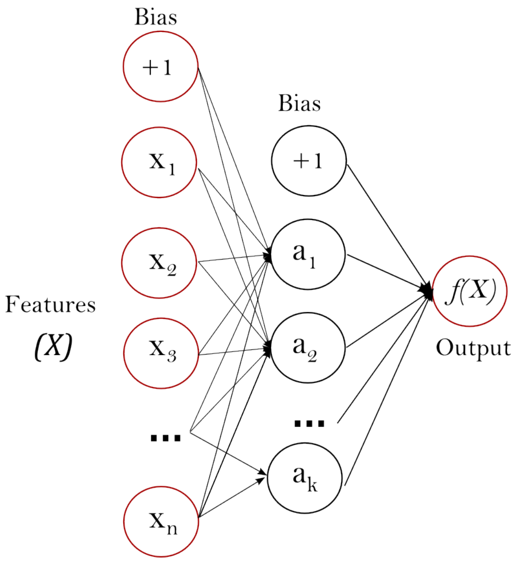

Figura 38: Rede neural MLP

A função custo a ser utilizada é a Entropia cruzada, ou função verossimilhança:

$$l(\theta) = -\sum_{t=1}^{N} \nu(t) log(\hat{\nu}) + (1 - \nu(t)) log(1 - \hat{\nu}(t))$$

A função de ativação escolhida para os neurônios das camadas intermediárias foi a Tangente hiperbólica:

$$u(t) = \frac{1 - exp(-z(t))}{1 + exp(-z(t))}$$

Método de ajuste dos parâmetros escolhido foi o Gradiente descendente estocástico. Aprendizado através do Backpropagation.

O Perceptron de Múltiplas Camadas é capaz de aprender modelos não lineares.

Durante a execução do algoritmo notou-se que os resultados eram diferentes a cada execução. Isso se deve a inicialização aleatória dos parametros. Quando existem camadas escondidas a função custo não é convexa, portanto existe mais de um mínimo local.

Além disso, o método é bastante sensível a escala das variáveis de entrada, tornando necessária, mais que em outros métodos, a padronização das variáveis. Foi feita uma padronização de modo a obter média zero e desvio padrão 1. A padronização é calculada no conjunto de treinamento e a mesma transformação é aplicada para o conjunto de teste.

9.2 Resultados - (21)

Tabela 15: Matriz de confusão

	$\hat{C_1}$ **(Predita)**	$\hat{C_2}$**(Predita)**
C_1	20.20	1.00
C_2	0.40	35.30

- $ACC = 97.35\%$
- $ERR =$
- $AUC = 0.9708\%$
- $PRE(C1) = 0.9806$
- $REC(C1) = 0.9528$
- $PRE(C2) = 0.9725$
- $REC(C2) = 0.9888$

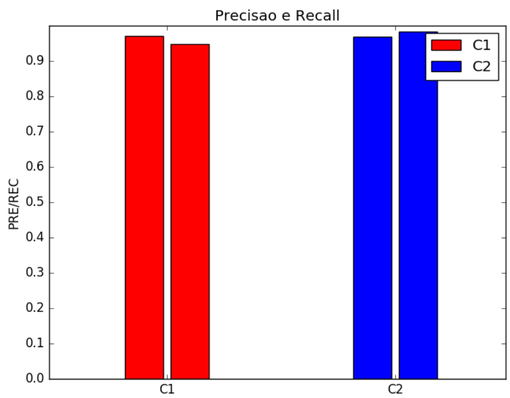

Figura 39: Precisão e Recall

9.3 Resultados - (100)

Tabela 16: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.40	0.80
C_2	0.30	35.40

- $ACC = 98.07\%$
- $ERR =$
- $AUC = 0.9769$
- $PRE(C1) = 0.9855$
- $REC(C1) = 0.9623$
- $PRE(C2) = 0.9779$
- $REC(C2) = 0.9916$

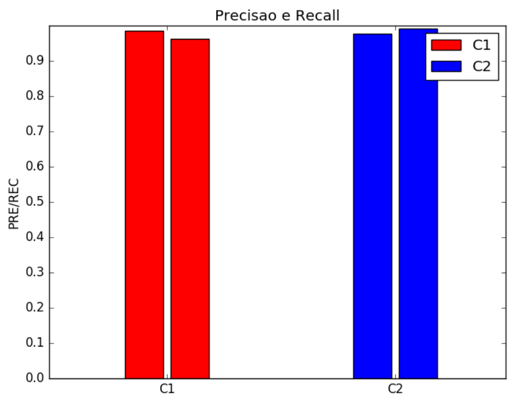

Figura 40: Precisão e Recall

9.4 Resultados - (10,10)

Tabela 17: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.30	0.90
C_2	0.30	35.40

- $ACC = 97.89\%$
- $ERR =$
- $AUC = 0.9746$
- $PRE(C1) = 0.9854$
- $REC(C1) = 0.9575$
- $PRE(C2) = 0.9752$
- $REC(C2) = 0.9916$

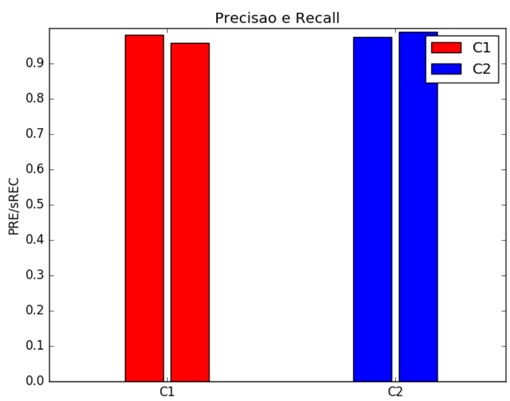

Figura 41: Precisão e Recall

10 Máquinas de Vetor de Suporte (SVC)

10.1 Formulação Matemática

O SVC é mais recomendado para vetores características de dimensões maiores. Função de núcleo utilizada: RBF. O problema de otimização para o ajuste de parâmetros pode ser escrito como:

$$\min_{w,b,\zeta} \frac{1}{2} w^T w + C \sum_{i=1}^{n} \zeta_i$$
$$\text{sujeito a } y_i(w^T \phi(x_i) + b) \geq 1 - \zeta_i,$$
$$\zeta_i \geq 0, i = 1, ..., n$$

$C = \frac{N}{\alpha}$
w : direção ortogonal ao hiperplano da função discriminante
O método busca maximizar a margem de separação.

10.2 Resultados

Tabela 18: Matriz de confusão

	$\hat{C}_1$ **(Predita)**	$\hat{C}_2$**(Predita)**
C_1	20.40	0.80
C_2	0.50	35.20

- $ACC = 97.72\%$
- $ERR =$
- $AUC = 0.9741$
- $PRE(C1) = 0.9761$
- $REC(C1) = 0.9623$
- $PRE(C2) = 0.9778$
- $REC(C2) = 0.9860$

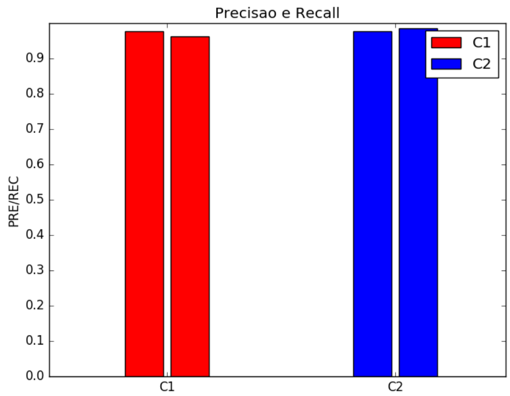

Figura 42: Precisão e Recall

11 Conclusão

A comparação entre os métodos pode ser vista na tabela 19.

Tabela 19: Resultados

	ACC	**AUC**
Baysiano Simples	0,9367	0,9266
Baysiano Quadrático	0,9578	0,9549
Regressão Logistica	0,9596	0,9563
Perceptron	0,9613	0,9615
MPL (21)	0,9735	0,9708
MPL(100)	**0,9807**	**0,9769**
MPL(10,10)	0,9789	0,9746
SVM	0,9772	0,9741

12 Apêndice

Tabela 20: Estatísticas básicas (todas as variáveis)

	Máximo	Mínimo	Média	Desvio Padrão	P 25	P 50	P 75
x_1	28.11	6.981	14.13	3.524	11.7	13.37	15.78
x_2	2.873	0.1115	0.4052	0.2773	0.2324	0.3242	0.4789
x_3	36.04	7.93	16.27	4.833	13.01	14.97	18.79
x_4	39.28	9.71	19.29	4.301	16.17	18.84	21.8
x_5	4.885	0.3602	1.217	0.5516	0.8339	1.108	1.474
x_6	49.54	12.02	25.68	6.146	21.08	25.41	29.72
x_7	188.5	43.79	91.97	24.3	75.17	86.24	104.1
x_8	21.98	0.757	2.866	2.022	1.606	2.287	3.357
x_9	251.2	50.41	107.3	33.6	84.11	97.66	125.4
x_{10}	2501	143.5	654.9	351.9	420.3	551.1	782.7
x_{11}	542.2	6.802	40.34	45.49	17.85	24.53	45.19
x_{12}	4254	185.2	880.6	569.4	515.3	686.5	1084
x_{13}	0.1634	0.05263	0.09636	0.01406	0.08637	0.09587	0.1053
x_{14}	0.03113	0.001713	0.007041	0.003003	0.005169	0.00638	0.008146
x_{15}	0.2226	0.07117	0.1324	0.02283	0.1166	0.1313	0.146
x_{16}	0.3454	0.01938	0.1043	0.05281	0.06492	0.09263	0.1304
x_{17}	0.1354	0.002252	0.02548	0.01791	0.01308	0.02045	0.03245
x_{18}	1.058	0.02729	0.2543	0.1573	0.1472	0.2119	0.3391
x_{19}	0.4268	0	0.0888	0.07972	0.02956	0.06154	0.1307
x_{20}	0.396	0	0.03189	0.03019	0.01509	0.02589	0.04205
x_{21}	1.252	0	0.2722	0.2086	0.1145	0.2267	0.3829
x_{22}	0.2012	0	0.04892	0.0388	0.02031	0.0335	0.074
x_{23}	0.05279	0	0.0118	0.00617	0.007638	0.01093	0.01471
x_{24}	0.291	0	0.1146	0.06573	0.06493	0.09993	0.1614
x_{25}	0.304	0.106	0.1812	0.02741	0.1619	0.1792	0.1957
x_{26}	0.07895	0.007882	0.02054	0.008266	0.01516	0.01873	0.02348
x_{27}	0.6638	0.1565	0.2901	0.06187	0.2504	0.2822	0.3179
x_{28}	0.09744	0.04996	0.0628	0.00706	0.0577	0.06154	0.06612
x_{29}	0.02984	0.000895	0.003795	0.002646	0.002248	0.003187	0.004558
x_{30}	0.2075	0.05504	0.08395	0.01806	0.07146	0.08004	0.09208